PROMPT — DATASET SINTÉTICO LONGITUDINAL OBSTÉTRICO Versão Final

==========
1. PAPEL E OBJETIVO
==========

Atua como especialista em Obstetrícia clínica, Epidemiologia perinatal e Ciência de Dados em Saúde.

Gera um dataset sintético longitudinal de 5000 trajetórias obstétricas. Cada linha representa uma grávida e o respetivo percurso desde a consulta inicial/pré-concecional até ao parto, puerpério e seguimento pós-natal.

Esta população é DELIBERADAMENTE ENRIQUECIDA em gravidezes de risco e nas complicações-alvo:
- diabetes gestacional;
- hipertensão gestacional;
- pré-eclâmpsia;
- macrossomia;
- parto pré-termo;
- restrição de crescimento fetal.

Deve conter também trajetórias SEM patologias-alvo (controlos), permitindo comparação entre perfis.

As proporções obtidas são proporções de amostragem/enriquecimento definidas para fins metodológicos e NÃO representam prevalências populacionais reais.

Os dados devem ser:
- totalmente sintéticos, sem qualquer dado real;
- clinicamente plausíveis;
- estatisticamente plausíveis;
- temporalmente coerentes;
- internamente consistentes;
- suficientemente variáveis, sem perfis determinísticos;
- auditáveis sempre que existam variáveis derivadas, flags ou diagnósticos.

IMPORTANTE:
A geração deve privilegiar primeiro a coerência das variáveis-base e das trajetórias e apenas depois calcular diagnósticos e flags. Nunca corrigir quotas alterando diretamente flags ou empurrando artificialmente variáveis contínuas para os limiares diagnósticos.

==========
2. PRINCÍPIO FUNDAMENTAL DE GERAÇÃO — SEM FLAGS ARBITRÁRIAS E SEM PATCHING DE LIMIARES
==========

Nunca aumentar a representação de uma patologia alterando isoladamente a respetiva flag.

Cada diagnóstico tem de EMERGIR de uma trajetória clínica coerente segundo:

perfil interno de geração
-> características basais e fatores de risco
-> evolução longitudinal
-> medições clínicas/laboratoriais
-> diagnóstico derivado
-> conduta
-> parto/outcomes
-> seguimento pós-natal.

Organizar internamente as trajetórias em perfis de geração:
A: sem patologias-alvo;
B: diabetes gestacional;
C: hipertensão gestacional;
D: pré-eclâmpsia;
E: macrossomia;
F: parto pré-termo;
G: restrição de crescimento fetal;
H: combinações clinicamente plausíveis.

Os perfis servem apenas para condicionar probabilisticamente a trajetória. NÃO são o diagnóstico final.

As flags finais têm de ser reconstruíveis a partir das variáveis exportadas sempre que forem declaradas auditáveis.

ANTI-LEAKAGE:
- o perfil interno de geração NÃO é exportado no dataset principal;
- se for necessário guardá-lo para auditoria, colocá-lo numa tabela de metadados separada;
- não criar variáveis cujo único fim seja revelar o perfil usado para gerar a linha.

ANTI-THRESHOLD-PATCHING:
- gerar primeiro as medições contínuas a partir de distribuições suaves e clinicamente coerentes;
- derivar só depois as flags através das regras definidas;

- nunca colocar deliberadamente muitos casos exatamente em 92 mg/dL, 140 mmHg, 90 mmHg, 300 mg, 4000 g, percentil 10 ou outros cutoffs apenas para cumprir quotas;
- se um mínimo de representação não for atingido, regenerar ou substituir trajetórias completas, e não alterar isoladamente o valor diagnóstico nem a respetiva flag.

==========
3. SCHEMA FECHADO E IDENTIFICADOR — REGRAS DURAS
==========

- O dataset exportado tem EXATAMENTE as 162 variáveis do dicionário, com os mesmos nomes, nem uma coluna a mais nem a menos.
- NÃO criar colunas novas.
- Em particular, NÃO criar 'gestational_diabetes': a diabetes gestacional é representada unicamente por referred_to_gestational_diabetes_clinic.
- NÃO eliminar, renomear nem traduzir variáveis.
- patient_id é a PRIMEIRA coluna, presente em todas as linhas, único, sem nulos, no formato P + número com zeros à esquerda: P00001, P00002, ... até P05000.

Codificação:
- nunca misturar natureza semântica com forma de codificação;
- variáveis binárias exportadas apenas como 0/1:
  0 = não/negativo/ausente;
  1 = sim/positivo/presente;
- nunca texto em variáveis binárias;
- variáveis categóricas com conjunto fechado de valores permitidos;
- nunca misturar código numérico e texto na mesma variável;
- datas no formato ISO AAAA-MM-DD.

==========
4. ESTRUTURA E COERÊNCIA LONGITUDINAL
==========

Sequência temporal:
pré-conceção
-> início da gravidez
-> 1.º trimestre
-> 2.º trimestre
-> 3.º trimestre
-> parto
-> puerpério
-> ~4 meses pós-parto
-> ~6 meses pós-parto.

Nenhuma variável pode surgir antes do momento clínico em que seria observável.

Exemplos:

- macrossomia depende do peso ao nascer;
- prematuridade só se determina no parto;
- hipertensão gestacional e pré-eclâmpsia não podem ser diagnosticadas antes das 20 semanas;
- OGTT só existe quando a respetiva janela gestacional é atingida e quando a regra de fasting_glucose o permite;
- variáveis de puerpério apenas após o parto;
- EPDS pós-natal não influencia retroativamente valores pré-natais.

As variáveis dinâmicas devem evoluir de forma coerente e não por saltos artificiais não explicados.

Datas:
- preconception_consultation_date < last_menstrual_period quando a consulta existe;
- estimated_due_date = last_menstrual_period + 280 dias;
- datas de consultas em ordem cronológica;
- delivery_date depois de todas as consultas antenatais efetivamente realizadas;
- visit8_date depois do parto;
- date_4_months_postpartum depois de visit8_date;
- date_6_months_postpartum depois de date_4_months_postpartum.

==========
5. VARIÁVEIS DERIVADAS — REGRAS DURAS E AUDITABILIDADE REAL
==========

Toda a variável derivada indica no dicionário:
- variável(is)-base com o NOME EXATO usado no schema;
- regra de derivação;
- momento clínico;
- auditabilidade;
- justificação quando não for totalmente auditável.

Nunca marcar como auditável algo que não possa ser reconstruído exclusivamente a partir das 162 variáveis exportadas.

Nunca usar aliases ou nomes inexistentes no schema dentro do dicionário ou das regras.
Exemplos proibidos: "LMP", "due date", "blood_pressure_week29", "PA_repetition_3T", "Preconception_performed" ou qualquer outro nome que não corresponda exatamente a uma coluna do dataset.

Variáveis diretamente observadas/geradas, e não derivadas, devem ser identificadas como:
"medição sintética direta / não derivada"
e NÃO devem receber falsas variáveis-base.

Em particular:
- repeated_third_trimester_blood_pressure_systolic e repeated_third_trimester_blood_pressure_diastolic são novas medições sintéticas condicionadas à trajetória tensional; não são uma transformação matemática da primeira tensão;
- third_trimester_24h_proteinuria_mg é uma medição laboratorial sintética direta; não é derivada da pressão arterial.

Derivações obrigatórias:

- bmi = visit1_weight_kg / (height_m^2)

- estimated_due_date = last_menstrual_period + 280 dias

- ultrasound_adjusted_estimated_due_date:
  deve ser reconstruível conforme a regra específica da secção 5A abaixo.

- preterm_birth = 1 se e somente se gestational_age_at_delivery_weeks < 37

- macrosomia = 1 se e somente se birth_weight_g >= 4000

- fetal_growth_restriction = 1 se e somente se
  estimated_fetal_weight_third_trimester_percentile < 10,
  quando esse percentil estiver disponível

- anemia_first_trimester = 1 se e somente se hemoglobin_first_trimester < 11

- anemia_second_trimester = 1 se e somente se hemoglobin_second_trimester < 10.5

- anemia_third_trimester = 1 se e somente se hemoglobin_third_trimester < 10.5,
  quando hemoglobin_third_trimester existir

- postpartum_anemia = 1 se e somente se postpartum_hemoglobin < 10

- EPDS_ge_12 = 1 se e somente se EPDS_score >= 12

- Goodwin_score_visit3/4/5/6/8 são inteiros;
  risco:
  0–2 = low;
  3–6 = medium;
  >=7 = high.

As hemoglobinas e EPDS_score têm de existir sempre que as respetivas flags forem declaradas auditáveis.

==========
5A. DATAÇÃO ECOGRÁFICA E EDD AJUSTADA — REGRA DURA NOVA
==========

A variável gestational_age_at_first_trimester_ultrasound_days NÃO pode ser apenas uma cópia da idade gestacional cronológica calculada pela LMP.

Definir internamente:

calendar_gestational_age_at_ultrasound_days =
first_trimester_ultrasound_date - last_menstrual_period

Este valor interno NÃO é exportado como nova coluna, pois pode ser reconstruído pelas duas datas.

Gerar depois uma discrepância ecográfica sintética clinicamente plausível, por exemplo entre -10 e +10 dias, com maior densidade perto de 0.

A variável exportada deve obedecer a:

gestational_age_at_first_trimester_ultrasound_days =
calendar_gestational_age_at_ultrasound_days
+ discrepância_ecográfica_sintética

Logo, a discrepância deve ser reconstruível no CSV:

discrepância_ecográfica_sintética =
gestational_age_at_first_trimester_ultrasound_days
- (first_trimester_ultrasound_date - last_menstrual_period)

Regra para ultrasound_adjusted_estimated_due_date:

- se ABS(discrepância_ecográfica_sintética) < 7 dias:
  ultrasound_adjusted_estimated_due_date = estimated_due_date

- se ABS(discrepância_ecográfica_sintética) >= 7 dias:
  ultrasound_adjusted_estimated_due_date =
  first_trimester_ultrasound_date
  + (280 - gestational_age_at_first_trimester_ultrasound_days) dias

dating_confirmed_by_first_trimester_ultrasound deve ser coerente com a definição semântica presente no dicionário e com a informação acima.

É PROIBIDO usar dating_confirmed_by_first_trimester_ultrasound como um driver oculto para alterar a EDD se a discrepância reconstruível não justificar essa alteração.

Na validação final, recalcular ultrasound_adjusted_estimated_due_date linha a linha exclusivamente a partir das colunas exportadas. Taxa de violação exigida: 0%.

==========
6. DIABETES GESTACIONAL — OGTT — REGRA DURA
==========

- OGTT_performed = 1 apenas se fasting_glucose < 92 mg/dL.

- Se fasting_glucose >= 92 mg/dL:
  OGTT_performed = 0;
  OGTT_fasting_glucose = NA;
  OGTT_1h_glucose = NA;
  OGTT_2h_glucose = NA;
  referred_to_gestational_diabetes_clinic = 1,
  exceto se pregestational_diabetes = 1.

- Nunca fasting_glucose >= 92 com OGTT_performed = 1.
- Nunca preencher valores OGTT quando OGTT_performed = 0.

Quando OGTT_performed = 1:
referred_to_gestational_diabetes_clinic = 1 se pelo menos um:
- OGTT_fasting_glucose >= 92
- OGTT_1h_glucose >= 180
- OGTT_2h_glucose >= 153

caso contrário = 0.

EXCLUSIVIDADE DURA:
se pregestational_diabetes = 1:
referred_to_gestational_diabetes_clinic = 0.

Taxa de violação exigida: 0%.

ANTI-HEAPING:
os valores de fasting_glucose e OGTT devem ser gerados como medições contínuas/realisticamente arredondadas antes da aplicação da regra diagnóstica. Não usar 92, 180 ou 153 de forma excessiva para criar positivos.

==========
7. HIPERTENSÃO GESTACIONAL E PRÉ-ECLÂMPSIA — REGRA DURA
==========

Só após 20 semanas.

Definição operacional de hipertensão:

blood_pressure_week29_systolic >= 140
OU
blood_pressure_week29_diastolic >= 90

ou, quando disponíveis, as medições:
repeated_third_trimester_blood_pressure_systolic >= 140
OU
repeated_third_trimester_blood_pressure_diastolic >= 90.

Idealmente deve existir confirmação por medição repetida quando a primeira medição está elevada.

Distinção pela proteinúria de 24 h:

- hipertensão após 20 semanas + third_trimester_24h_proteinuria_mg < 300
  -> gestational_hypertension = 1

- hipertensão após 20 semanas + third_trimester_24h_proteinuria_mg >= 300
  -> preeclampsia = 1

gestational_hypertension e preeclampsia NÃO podem representar simultaneamente o diagnóstico final da mesma situação.

Pode existir evolução clínica de hipertensão gestacional para pré-eclâmpsia, mas o estado final exportado deve ser logicamente consistente.

A tensão nas fases iniciais não deve ser artificialmente elevada em todos os casos que mais tarde desenvolvem hipertensão.
Permitir subida progressiva.

A modelação de pré-eclâmpsia é simplificada e isso deve ser declarado nas limitações.

ANTI-HEAPING:
- não concentrar artificialmente casos em 140/90;
- não concentrar artificialmente pré-eclâmpsia exatamente em 300 mg;
- gerar BP e proteinúria primeiro e derivar depois o diagnóstico.

==========
8. PESO MATERNO E GANHO PONDERAL — REGRA REVISTA
==========

Registar peso longitudinal:
visit1_weight_kg ... visit8_weight_kg
e, quando aplicável:
weight_4_months_postpartum_kg
weight_6_months_postpartum_kg.

Para gravidezes de termo, manter como referência de ganho gestacional total por BMI basal:

- bmi < 18.5 -> 12.5–18 kg
- bmi 18.5–24.9 -> 11.5–16 kg
- bmi 25–29.9 -> 7–11.5 kg
- bmi >=30 -> 5–9 kg

Estas faixas são ALVOS PARA TRAJETÓRIAS QUE ATINGEM O TERMO/FINAL DA GESTAÇÃO e NÃO devem ser impostas integralmente a uma gravidez que termina precocemente.

No 1.º trimestre:
- ganho acumulado esperado aproximadamente 0.5–2 kg, com variabilidade individual.

Depois:
- ganho progressivo e não linear;
- permitir variação fisiológica entre consultas;
- evitar sequências rigidamente lineares;
- pequenas oscilações são permitidas desde que a trajetória global seja plausível.

REGRA OPERACIONAL PARA PRÉ-TERMO:

1. Determinar a última consulta antenatal efetivamente realizada.
2. Determinar a idade gestacional dessa consulta através de:
   (last_antenatal_visit_date - last_menstrual_period) / 7.
3. O ganho esperado nessa data deve corresponder apenas à fração da gestação já decorrida.
4. NÃO exigir a uma grávida que termina a gravidez antes do termo que já tenha atingido o intervalo total previsto para 40 semanas.

Método interno recomendado de geração:
- gerar primeiro um target_term_weight_gain individual dentro da faixa correspondente ao BMI;
- gerar ganho no 1.º trimestre aproximadamente entre 0.5 e 2 kg;
- fazer o ganho restante acumular progressivamente entre o fim do 1.º trimestre e cerca de 40 semanas;
- se a trajetória terminar antes, usar apenas o ganho acumulado esperado até à última consulta realizada.

O target_term_weight_gain é uma variável LATENTE e NÃO é exportada.

total_weight_gain =
peso da ÚLTIMA consulta antenatal efetivamente realizada
- visit1_weight_kg.

Nas gravidezes de termo, corresponde habitualmente a:
visit7_weight_kg - visit1_weight_kg.

Nas pré-termo:
usar a última visitK_weight_kg não-NA anterior ao parto.

Nunca calcular total_weight_gain a partir de uma consulta a NA nem de uma consulta posterior ao parto.

VALIDAÇÃO DO GANHO PONDERAL:
- para gestações de termo, verificar diretamente as faixas totais por BMI;
- para pré-termo, verificar coerência do ganho acumulado com a idade gestacional da última consulta, e NÃO aplicar cegamente as faixas de termo;
- a média de total_weight_gain deve aumentar de forma geral à medida que aumenta a idade gestacional no parto/última consulta.

postpartum_weight_loss =
peso da última consulta antenatal realizada
- visit8_weight_kg.

Manter intervalo operacional de 5–8 kg quando clinicamente aplicável e quando ambas as medições existirem.

==========
9. RASTREIOS, SUPLEMENTAÇÃO E OUTRAS VARIÁVEIS
==========

- VIH:
HIV1_HIV2_antibodies_first_trimester / _third_trimester:
normal = negativo.

- Rubéola:
1.º trimestre;
se não imune, repetir no 2.º.

- Toxoplasmose:
1.º trimestre;
se negativo, repetir no 2.º;
se ainda negativo, repetir no 3.º.

- HBsAg:
1.º trimestre;
HBsAg_third_trimester quando indicado.
Se não vacinada e negativo, repetir no 3.º.

- Ácido fólico:

folic_acid_dose = 400 µg se folic_acid_started = 1 sem alto risco;
5000 µg apenas em alto risco:
filho anterior com DTN;
história familiar;
diabetes pré-gestacional;
epilepsia sob anticonvulsivantes;
alterações do metabolismo do folato;
bmi >= 30;
doença celíaca;
doença inflamatória intestinal;
metotrexato;
trimetoprim.

Se folic_acid_started = 0:
folic_acid_dose = NA.

Permitir aproximadamente 5–10% de não adesão.

- Iodeto de potássio:
suplementação ao longo de gravidez/puerpério/aleitamento;
aproximadamente 5–10% de não adesão.

- BCF:
fetal_heartbeat_present_visit2..visit7 com dinâmica longitudinal.
Após viabilidade, uma gravidez evolutiva não deve apresentar desaparecimentos e reaparecimentos arbitrários sem evento clínico correspondente.

- Aleitamento:
transições permitidas:
exclusive -> exclusive / mixed / formula
mixed -> mixed / formula
formula -> formula

Nunca formula -> exclusive.

==========
10. PARTO PRÉ-TERMO — ESPECTRO, MECANISMO E TRUNCAGEM — REGRAS DURAS
==========

ESPECTRO DE GRAVIDADE dentro dos pré-termos, com variabilidade contínua:

- tardio: 34 a <37 semanas -> ~70%
- moderado: 32 a <34 -> ~12%
- muito pré-termo: 28 a <32 -> ~12%
- extremo: <28 -> ~6%

Estas proporções são aproximadas, não targets que justifiquem manipular diretamente gestational_age_at_delivery_weeks para valores de fronteira.

MECANISMO:
o excesso de pré-termos NÃO se obtém aumentando uniformemente a probabilidade em toda a população.

Deve emergir de causas e fatores de risco:

- taxa basal espontânea em pessoas sem patologia-alvo;
- pré-eclâmpsia eleva fortemente o risco, alvo RR aproximadamente 4–5x;
- pré-termo associado a pré-eclâmpsia é frequentemente indicado:
  maior probabilidade de labor_induction = 1 e/ou delivery_type = cesarean;
  concentrado sobretudo entre 30–36 semanas;
- anemia_third_trimester = 1 eleva moderadamente o risco, alvo RR aproximadamente 1.5–2x;
- muito/extremo pré-termo (<32 semanas) deve ser maioritariamente espontâneo/não hipertensivo, pois medições de week29 podem não existir.

Permitir:
- pré-eclâmpsia a termo;
- parto pré-termo sem pré-eclâmpsia;
- anemia sem parto pré-termo;
- parto pré-termo sem anemia.

preterm_birth resulta exclusivamente de:
gestational_age_at_delivery_weeks < 37.

TRUNCAGEM DO CALENDÁRIO DE CONSULTAS:

Uma consulta só existe se a gravidez ainda decorria na respetiva janela:

visit2 ≈16 semanas
visit3 ≈20–22
visit4 ≈28–30
visit5 ≈32
visit6 ≈34–36
visit7 ≈36–40

Se o parto for antes da janela, ficam a NA:
visitK_date
visitK_weight_kg
potassium_iodide_supplementation_visitK
fetal_heartbeat_present_visitK
Goodwin_score_visitK
Goodwin_risk_visitK
quando aplicável.

Exames do 3.º trimestre:

- parto <29 semanas:
blood_pressure_week29_systolic = NA
blood_pressure_week29_diastolic = NA
repeated_third_trimester_blood_pressure_systolic = NA
repeated_third_trimester_blood_pressure_diastolic = NA
third_trimester_24h_proteinuria_mg = NA

- parto <28 semanas:
hemoglobin_third_trimester = NA
anemia_third_trimester = NA
e deve ser documentado que esta flag deixa de ser auditável/não observável nesse caso.

- ecografia de crescimento do 3.º trimestre não atingida:
estimated_fetal_weight_third_trimester = NA
estimated_fetal_weight_third_trimester_percentile = NA
abdominal_circumference_third_trimester = NA
head_circumference_third_trimester = NA
femur_length_third_trimester = NA

- parto <35 semanas:
GBS_result = NA

- janela OGTT não atingida:
OGTT_performed = 0
OGTT_fasting_glucose = NA
OGTT_1h_glucose = NA
OGTT_2h_glucose = NA

Consequências:
- total_weight_gain usa a última consulta realizada;
- fetal_growth_restriction só pode ser diagnosticado quando o percentil existir;
- se o percentil não existir por parto muito precoce, não inventar diagnóstico observável;
- nenhuma data antenatal pode ser posterior a delivery_date;
- a percentagem de consultas em falta deve crescer à medida que a idade gestacional ao parto diminui.

==========
11. MACROSSOMIA E CRESCIMENTO FETAL
==========

macrosomia deve emergir de:
- características maternas;

- bmi elevado;
- eventual diabetes gestacional;
- trajetória de crescimento fetal;
- idade gestacional ao parto;
- peso ao nascer.

Diagnóstico:
macrosomia = 1 se e somente se birth_weight_g >= 4000.

birth_weight_g deve ser coerente com gestational_age_at_delivery_weeks:
- em média aumenta com a idade gestacional;
- pré-termo deve apresentar peso proporcionalmente menor;
- macrossomia deve ficar praticamente restrita a partos >=37 semanas.

Gerar também macrossomia sem diabetes gestacional quando plausível.

fetal_growth_restriction:
- associado probabilisticamente a menor estimated_fetal_weight_third_trimester;
- associado probabilisticamente a menor birth_weight_g;
- não pode coexistir com um peso neonatal elevado incoerente.

REGRA DURA DE EXCLUSÃO PARA EVITAR A INCOERÊNCIA OBSERVADA:
- se fetal_growth_restriction = 1, então macrosomia = 0;
- se macrosomia = 1, então fetal_growth_restriction = 0;
- se fetal_growth_restriction = 1, birth_weight_g deve ser <4000 g.

Não gerar trajetórias com:
estimated_fetal_weight_third_trimester_percentile <10
e simultaneamente birth_weight_g >=4000.

Para FGR, a trajetória de crescimento do 3.º trimestre e o peso ao nascer devem apontar globalmente na mesma direção clínica.

ANTI-HEAPING DE MACROSSOMIA:
não usar 4000 g como valor de correção.
Casos com macrosomia devem ocupar uma distribuição acima de 4000 g e casos não macrossómicos uma distribuição abaixo, com continuidade plausível em torno do cutoff.

==========
12. ASSOCIAÇÕES EPIDEMIOLÓGICAS — PROBABILÍSTICAS, NUNCA DETERMINÍSTICAS
==========

- bmi elevado -> maior probabilidade de diabetes gestacional, hipertensão, pré-eclâmpsia, macrossomia e cesariana;

- idade materna >=35 -> maior probabilidade de diabetes gestacional, hipertensão e cesariana;
- diabetes gestacional -> maior probabilidade de indução, macrossomia e cesariana;
- pré-eclâmpsia -> maior probabilidade de parto pré-termo;
- anemia -> maior probabilidade de parto pré-termo;
- fetal_growth_restriction -> menor peso ao nascer.

Devem existir exemplos positivos e negativos em todos os grupos:

- GDM sem macrossomia;
- macrossomia sem GDM;
- PE a termo;
- pré-termo sem PE;
- obesas sem complicações;
- bmi normal com complicações;
- anemia sem pré-termo;
- pré-termo sem anemia.

Nenhuma destas associações deve tornar-se determinística.

==========
13. COMPOSIÇÃO DA COORTE E ENRIQUECIMENTO
==========

Requisitos de composição mínimos, ajustáveis pelo investigador.

NÃO são prevalências reais.

N_TOTAL = 5000

MIN_GDM = 700 (~14%)
MIN_HIPERTENSAO_GESTACIONAL = 500 (~10%)
MIN_PREECLAMPSIA = 350 (~7%)
MIN_MACROSSOMIA = 650 (~13%)
MIN_PARTO_PRETERMO = 750 (~15%)
MIN_fetal_growth_restriction = 500 (~10%)

Manter >=30% de trajetórias SEM nenhuma patologia-alvo.

Permitir sobreposição clinicamente plausível entre patologias.

Não somar os mínimos como grupos mutuamente exclusivos.

Se algum mínimo não for atingido:
- gerar trajetórias adicionais ou substituir trajetórias completas;
- recalcular todas as medições e outcomes da trajetória;

- NÃO alterar artificialmente flags;
- NÃO mover uma medição para exatamente o cutoff;
- NÃO alterar apenas a variável diagnóstica final.

==========
14. VARIABILIDADE E ANTI-ARTEFACTOS
==========

- 3–7% de missing estruturado apenas em variáveis não críticas;
- 5–10% de não adesão à suplementação quando aplicável;
- variação fisiológica e heterogeneidade de perfis;
- pequenas inconsistências administrativas plausíveis apenas se não violarem regras duras;
- não introduzir missing que torne impossível auditar uma flag declarada auditável;
- evitar perfis clínicos perfeitos;
- evitar relações determinísticas artificiais.

ANTI-HEAPING / ANTI-CUTOFF-ARTEFACT:

Para cada variável contínua usada num cutoff diagnóstico:
fasting_glucose
OGTT_fasting_glucose
OGTT_1h_glucose
OGTT_2h_glucose
blood_pressure_week29_systolic
blood_pressure_week29_diastolic
repeated_third_trimester_blood_pressure_systolic
repeated_third_trimester_blood_pressure_diastolic
third_trimester_24h_proteinuria_mg
estimated_fetal_weight_third_trimester_percentile
birth_weight_g
hemoglobinas
EPDS_score

deve existir uma distribuição plausível em torno dos limiares.

Não deve existir acumulação artificial exatamente no cutoff.

Regra de controlo:
- valores exatamente no cutoff podem existir por arredondamento natural;
- porém não devem constituir uma fração desproporcionada dos casos positivos;
- se o número exatamente no cutoff produzir um pico evidente quando comparado com valores imediatamente abaixo e acima, regenerar esses casos;
- como regra operacional, tentar manter <5% dos casos positivos exatamente no cutoff, salvo justificação clínica/documental;
- quotas de patologias nunca podem ser satisfeitas através de concentração no valor-limite.

==========
15. DICIONÁRIO DE DADOS — REGRAS DE QUALIDADE DOCUMENTAL
==========

O dicionário expandido deve ter uma linha por cada uma das 162 variáveis e usar SEMPRE os nomes exatos do schema.

Para cada variável indicar:
1. nome;
2. tipo semântico;
3. tipo exportado;
4. codificação;
5. valores permitidos / unidade / intervalo esperado;
6. momento de colheita;
7. valor esperado;
8. variáveis-base;
9. regra de derivação;
10. auditabilidade e respetiva justificação.

Regras:
- variáveis derivadas: listar apenas variáveis-base que realmente existem no CSV;
- variáveis diretamente medidas/geradas: "variáveis-base = não aplicável";
- não inventar aliases;
- não declarar uma variável direta como derivada de outra apenas por correlação clínica;
- repeated BP é nova medição, não derivação matemática;
- proteinúria de 24 h é medição direta, não derivação da pressão;
- toda a regra declarada auditável deve ser recalculável a partir do CSV.

Antes de exportar o dicionário:
validar automaticamente que todos os nomes citados em "variáveis-base" pertencem ao conjunto oficial das 162 colunas.

Taxa de referências a variáveis inexistentes: 0%.

==========
16. VALIDAÇÃO FINAL — AUDITORIA LINHA A LINHA
==========

Antes de exportar, validar sistematicamente e corrigir/regenerar qualquer linha não conforme.

REGRAS DURAS DEVEM TER 0% DE VIOLAÇÕES.

Validar:

- schema exato de 162 colunas;
- ausência de 'gestational_diabetes';
- patient_id presente, único, sem nulos, primeira coluna, formato P00001…P05000;
- tipos;
- codificação 0/1;
- categorias permitidas;
- datas ISO;
- cronologia;
- estimated_due_date;
- ultrasound_adjusted_estimated_due_date reconstruível;
- bmi;
- trajetória de peso;
- total_weight_gain usando a última consulta efetivamente realizada;
- ganho ponderal de termo dentro das faixas por BMI;
- ganho de pré-termo coerente com a idade gestacional, sem exigir faixa total de termo;
- postpartum_weight_loss;
- anemias;
- fasting_glucose/OGTT;
- referred_to_gestational_diabetes_clinic;
- exclusividade pregestational_diabetes × referred_to_gestational_diabetes_clinic;
- gestational_hypertension;
- preeclampsia;
- macrosomia;
- preterm_birth;
- fetal_growth_restriction;
- exclusividade FGR × macrosomia;
- EPDS;
- Goodwin;
- aleitamento;
- coerência variáveis-base ↔ flags;
- missingness;
- coocorrências;
- truncagem do calendário;
- composição final da população;
- qualidade do dicionário.

VALIDAÇÕES ESTATÍSTICAS OBRIGATÓRIAS:

1. Distribuição de gestational_age_at_delivery_weeks nos pré-termos:
   - <28
   - 28–<32
   - 32–<34
   - 34–<37

2. RR de preterm_birth dado preeclampsia:
   alvo aproximadamente 4–5x.

3. RR de preterm_birth dado anemia_third_trimester:
alvo aproximadamente 1.5–2x, calculado apenas entre casos em que anemia_third_trimester seja observável.

4. RR de macrosomia dado bmi>=30:
alvo aproximadamente 2x, além da associação com diabetes gestacional.

5. Truncagem:
- % de visitK_date a NA aumenta à medida que a idade gestacional ao parto diminui;
- 0 datas de consulta posteriores ao parto.

6. total_weight_gain:
- coincide exatamente com última visita antenatal não-NA menos visit1_weight_kg;
- em pré-termos não é validado contra uma faixa de 40 semanas;
- deve mostrar tendência global crescente com maior duração da gestação.

7. Exclusividade:
pregestational_diabetes = 1
e referred_to_gestational_diabetes_clinic = 1
-> contagem obrigatória = 0.

8. FGR × macrossomia:
fetal_growth_restriction = 1 e macrosomia = 1
-> contagem obrigatória = 0.

9. EDD ajustada:
recalcular ultrasound_adjusted_estimated_due_date a partir de:
last_menstrual_period,
estimated_due_date,
first_trimester_ultrasound_date,
gestational_age_at_first_trimester_ultrasound_days.
-> discrepâncias obrigatórias = 0.

10. Threshold heaping:
reportar contagem e percentagem de valores exatamente nos principais cutoffs:
- fasting glucose = 92
- OGTT fasting = 92
- OGTT 1h = 180
- OGTT 2h = 153
- SBP = 140
- DBP = 90
- proteinúria = 300
- birth_weight_g = 4000
- percentile = 10

- thresholds de hemoglobina
- EPDS = 12

Se existir um pico artificial evidente, regenerar antes da exportação.

11. Dicionário:
verificar que 100% das variáveis-base citadas correspondem a nomes existentes nas 162 colunas.

A confirmação de "0 violações" só pode ser apresentada após verificação computacional sistemática linha a linha.

O auto-relato do modelo NÃO é garantia suficiente.

Recomenda-se validação externa independente através de script dedicado sobre o CSV final.

==========
17. OUTPUT OBRIGATÓRIO
==========

Entregar:

1. Dataset sintético final:
   CSV ou XLSX;
   5000 × 162;
   patient_id na primeira coluna.

2. Dicionário de dados expandido por variável:
   nome;
   tipo semântico;
   tipo exportado;
   codificação;
   valores permitidos;
   momento de colheita;
   valor esperado;
   variáveis-base;
   regra de derivação;
   auditabilidade;
   justificação quando não auditável.

3. Regras de geração.

4. Assunções clínicas.

5. Relatório de validação final.

6. Tabela de representação:
  número e percentagem de cada patologia-alvo.

7. Tabela das principais coocorrências.

8. Relatório de violações ANTES da correção/regeneração:
  tipo de violação;
  número de linhas;
  percentagem;
  ação corretiva aplicada.

9. Confirmação de 0 violações em todas as regras duras após correção,
  com ressalva explícita de que validação externa independente continua recomendada.

10. Relatório específico de anti-heaping:
  contagem nos thresholds,
  comparação com regiões adjacentes,
  indicação das regenerações efetuadas.

11. Limitações.

==========
18. LIMITAÇÕES E TRANSPARÊNCIA
==========

Declarar explicitamente:

- dataset totalmente sintético, sem ligação a pacientes reais;
- população deliberadamente enriquecida;
- proporções NÃO representam prevalências reais;
- esta coorte deve ser descrita como uma "risk-enriched synthetic obstetric cohort" ou equivalente, e não como uma população representativa de gravidez de baixo risco;
- destinado a investigação metodológica, ML, IA Generativa e Explainable AI;
- não substitui dados epidemiológicos reais;
- não se destina a decisão clínica;
- qualquer regra ou variável não auditável tem de ser identificada;
- modelação de pré-eclâmpsia simplificada;
- crescimento fetal e biometria são aproximações sintéticas;
- não alegar validade clínica/epidemiológica para aspetos que o schema não permite verificar.

==========
19. NOTA PARA UTILIZAÇÃO EM MACHINE LEARNING / CLUSTERING
==========

O dataset deve permitir análise de ML e XAI sem leakage estrutural desnecessário.

No relatório metodológico, identificar pares/grupos de variáveis em que uma flag é derivada deterministicamente de uma variável-base, por exemplo:

- gestational_age_at_delivery_weeks -> preterm_birth
- birth_weight_g -> macrosomia
- hemoglobin_* -> anemia_*
- EPDS_score -> EPDS_ge_12
- estimated_fetal_weight_third_trimester_percentile -> fetal_growth_restriction
- BP + proteinúria -> gestational_hypertension / preeclampsia

Não eliminar estas variáveis do dataset, pois fazem parte do schema fechado.

Porém, documentar que em tarefas de clustering ou modelação não supervisionada não é recomendável incluir simultaneamente, sem justificação, a variável-base contínua e a respetiva flag determinística, pois isso pode duplicar artificialmente o peso do mesmo fenómeno clínico.

==========
20. CRITÉRIO FINAL DE ACEITAÇÃO
==========

O dataset só pode ser considerado pronto para exportação quando:

- tiver exatamente 5000 × 162;
- todas as regras duras apresentarem 0 violações;
- as flags forem reconstruíveis quando declaradas auditáveis;
- a EDD ajustada for integralmente reconstruível;
- não existir coexistência FGR + macrossomia;
- a regra de ganho ponderal tratar separadamente gestações de termo e pré-termo;
- não existirem picos artificiais evidentes nos thresholds usados para atingir quotas;
- o dicionário não referenciar qualquer variável inexistente;
- os mínimos de enriquecimento forem atingidos por trajetórias completas clinicamente coerentes e não por manipulação direta de flags ou valores-limite.

==========
FIM DO PROMPT
==========