==========

1. PAPEL E OBJETIVO

==========

Atua como especialista em Obstetrícia clínica, Epidemiologia perinatal e Ciência de Dados em Saúde.

Gera um dataset sintético longitudinal de 5000 trajetórias obstétricas. Cada linha representa uma grávida e o respetivo percurso desde a consulta inicial/pré-concecional até ao parto, puerpério e seguimento pós-natal.

Esta população é DELIBERADAMENTE ENRIQUECIDA em gravidezes de risco e nas complicações-alvo:

- diabetes gestacional;
- hipertensão gestacional;
- pré-eclâmpsia;
- macrossomia;
- parto pré-termo;
- restrição de crescimento fetal.

Deve conter também trajetórias SEM patologias-alvo (controlos), permitindo comparação entre perfis.

As proporções obtidas são proporções de amostragem/enriquecimento definidas para fins metodológicos e NÃO representam prevalências populacionais reais.

Os dados devem ser:

- totalmente sintéticos, sem qualquer dado real;

- clinicamente plausíveis;
- estatisticamente plausíveis;
- temporalmente coerentes;
- internamente consistentes;
- suficientemente variáveis, sem perfis determinísticos;
- auditáveis sempre que existam variáveis derivadas, flags ou diagnósticos.

IMPORTANTE:
A geração deve privilegiar primeiro a coerência das variáveis-base e das trajetórias e apenas depois calcular diagnósticos e flags. Nunca corrigir quotas alterando diretamente flags ou empurrando artificialmente variáveis contínuas para os limiares diagnósticos.

ÂMBITO DESTE PEDIDO:
Produzir o dataset e os documentos que descrevem a sua geração. A avaliação independente do resultado será realizada posteriormente, numa etapa separada. Não solicitar programas, ficheiros de configuração ou relatórios de um avaliador como condição para gerar os dados. Usar o schema e o dicionário fornecidos para definir os nomes e a semântica das 162 variáveis.

==========

2. PRINCÍPIO FUNDAMENTAL DE GERAÇÃO — SEM FLAGS ARBITRÁRIAS E SEM PATCHING DE LIMIARES

==========

Nunca aumentar a representação de uma patologia alterando isoladamente a respetiva flag.

Cada diagnóstico tem de EMERGIR de uma trajetória clínica coerente segundo:

perfil interno de geração

-> características basais e fatores de risco

-> evolução longitudinal

-> medições clínicas/laboratoriais

-> diagnóstico derivado

-> conduta

-> parto/outcomes

-> seguimento pós-natal.

Organizar internamente as trajetórias em perfis de geração:

A: sem patologias-alvo;

B: diabetes gestacional;

C: hipertensão gestacional;

D: pré-eclâmpsia;

E: macrossomia;

F: parto pré-termo;

G: restrição de crescimento fetal;

H: combinações clinicamente plausíveis.

Os perfis servem apenas para condicionar probabilisticamente a trajetória. NÃO são o diagnóstico final.

As flags finais têm de ser reconstruíveis a partir das variáveis exportadas sempre que forem declaradas auditáveis.

ANTI-LEAKAGE:

- o perfil interno de geração NÃO é exportado no dataset principal;

- se for necessário guardá-lo para auditoria, colocá-lo numa tabela de metadados separada;

- não criar variáveis cujo único fim seja revelar o perfil usado para gerar a linha.

ANTI-THRESHOLD-PATCHING:

- gerar primeiro as medições contínuas a partir de distribuições suaves e clinicamente coerentes;

- derivar só depois as flags através das regras definidas;

- nunca colocar deliberadamente muitos casos exatamente em 92 mg/dL, 140 mmHg, 90 mmHg, 300 mg, 4000 g, percentil 10 ou outros cut-offs apenas para cumprir quotas;

- se um mínimo de representação não for atingido, regenerar ou substituir trajetórias

completas, e não alterar isoladamente o valor diagnóstico nem a respetiva flag.

==========

3. SCHEMA FECHADO E IDENTIFICADOR — REGRAS DURAS

==========

- O dataset exportado tem EXATAMENTE as 162 variáveis do dicionário, com os mesmos nomes, nem uma coluna a mais nem a menos.

- NÃO criar colunas novas.

- Em particular, NÃO criar 'gestational_diabetes'. Manter o campo existente referred_to_gestational_diabetes_clinic com o significado de referenciação.
No cenário assistencial definido na secção 6, a referenciação acompanha os casos identificados; não a apresentar como sinónimo clínico universal de DG.

- NÃO eliminar, renomear nem traduzir variáveis.

- patient_id é a PRIMEIRA coluna, presente em todas as linhas, único, sem nulos, no formato P + número com zeros à esquerda: P00001, P00002, ... até P05000.

Codificação:

- nunca misturar natureza semântica com forma de codificação;
- variáveis binárias exportadas apenas como 0/1:
  0 = não/negativo/ausente;
  1 = sim/positivo/presente;
- nunca texto em variáveis binárias;
- variáveis categóricas com conjunto fechado de valores permitidos;
- nunca misturar código numérico e texto na mesma variável;
- datas no formato ISO AAAA-MM-DD.

CONVENÇÕES DE EXPORTAÇÃO DO DICIONÁRIO:

- estimated_fetal_weight_third_trimester_percentile: inteiro entre 1 e 99, inclusive, quando a observação existe; caso contrário, NA.
- gestational_age_at_first_trimester_ultrasound_days: inteiro entre 63 e 97 dias, inclusive, neste desenho de ecografia do primeiro trimestre.
- uterine_fundal_height_postpartum: cm acima da sínfise púbica, entre 0 e 8 neste desenho; 0 significa útero não palpável. Não usar medida relativa ao umbigo ou uma altura uterina antenatal nesta coluna.
- birth_weight_g e Bishop_score: inteiros; Bishop_score entre 0 e 13.
- EPDS_score: inteiro entre 0 e 30; Goodwin_score: inteiro não negativo.
- medidas de peso e hemoglobina: precisão explícita no dicionário.
- tipos, categorias e unidades das restantes variáveis: os do dicionário.

Estes limites de representação são escolhas do dicionário do projeto, não limites universais de normalidade clínica. Nunca substituir um valor em falta

por 0. Não gerar valores incompatíveis para depois os recortar para o limite.

==========

4. ESTRUTURA E COERÊNCIA LONGITUDINAL

==========

Sequência temporal:

pré-conceção

-> início da gravidez

-> 1.o trimestre

-> 2.o trimestre

-> 3.o trimestre

-> parto

-> puerpério

-> ~4 meses pós-parto

-> ~6 meses pós-parto.

Nenhuma variável pode surgir antes do momento clínico em que seria observável.

Exemplos:

- macrossomia depende do peso ao nascer;

- prematuridade só se determina no parto;

- neste cenário, a hipertensão gestacional e a pré-eclâmpsia são representadas a partir de 20 semanas; não extrapolar essa restrição do desenho a todos os contextos clínicos possíveis;

- OGTT só existe quando a respetiva janela gestacional é atingida e quando a regra de fasting_glucose o permite;

- variáveis de puerpério apenas após o parto;

- EPDS pós-natal não influencia retroativamente valores pré-natais.

As variáveis dinâmicas devem evoluir de forma coerente e não por saltos artificiais não explicados.

Datas:

- preconception_consultation_date < last_menstrual_period quando a consulta existe;
- estimated_due_date = last_menstrual_period + 280 dias;
- datas de consultas em ordem cronológica;
- delivery_date depois de todas as consultas antenatais efetivamente realizadas;
- visit8_date = delivery_date + um número inteiro de 28 a 42 dias, inclusive;
- date_4_months_postpartum depois de visit8_date;
- date_6_months_postpartum depois de date_4_months_postpartum.

CONSULTA PUERPERAL REPRESENTADA POR VISIT8:

visit8 representa a consulta das 4 a 6 semanas após o parto. Gerar a data diretamente nessa janela, com variação entre trajetórias, e não entre 11 e 28 dias. Contactos precoces podem existir no percurso clínico, mas não são registados como visit8 neste desenho e não acrescentam colunas ao schema.

Gerar visit8_weight_kg e os campos explicitamente associados à consulta para o estado observado nessa data. Se uma variável postpartum tiver outro momento de colheita, como uma hemoglobina dos primeiros dias, documentá-lo como tal; não mudar-lhe artificialmente a data para a fazer coincidir com visit8. Gerar os campos sem data própria com um momento de referência explícito no dicionário.

Calcular postpartum_weight_loss a partir do peso antenatal disponível e do peso efetivamente gerado para visit8. A altura uterina e os restantes achados de recuperação devem corresponder ao seu momento puerperal documentado. Gerar os seguimentos de 4 e 6 meses a partir de delivery_date, por meses civis, mantendo-os posteriores a visit8 e pela ordem correta. Não deslocar todas as datas pós-natais por uma constante só para encaixar a consulta puerperal.

BASE TEMPORAL ÚNICA:

Depois de estabelecer ultrasound_adjusted_estimated_due_date, definir apenas internamente origem_gestacional = ultrasound_adjusted_estimated_due_date - 280 dias. Todas as idades gestacionais de consultas, exames e parto usam essa mesma origem. Não misturar DUM original e origem corrigida.

gestational_age_at_delivery_weeks =

round((delivery_date - origem_gestacional).days / 7, 2).

O campo representa semanas decimais, nunca a notação semanas.dias:

36 semanas e 5 dias = 36.71. Datas são dias civis inteiros. A DUM original

mantém-se em last_menstrual_period; origem_gestacional não é uma nova coluna.

Os momentos de observação são os definidos no desenho. Uma consulta não equivale automaticamente à data de todas as análises do mesmo trimestre.

Se o schema não exportar a data efetiva de um exame, descrevê-la nos metadados

de geração e não alegar reconstrução temporal integral apenas pelo CSV.

JANELA EXATA DA SEGUNDA CONSULTA:

Gerar visit2_date a partir de origem_gestacional + um número inteiro de 98

a 118 dias, inclusive, quando a consulta se realiza antes do parto. O dia 119 já corresponde a 17 semanas e não pertence à janela 14s–16s+6d escolhida para esta visita. Não gerar a data por arredondamento de semanas decimais que possa deslocar o resultado para o dia seguinte. Se não houver data possível anterior ao parto nessa janela, a visita fica ausente; não antecipá-la artificialmente. Esta regra usa a datação corrigida, não a DUM original.

==========

5. VARIÁVEIS DERIVADAS — REGRAS DURAS E AUDITABILIDADE REAL

==========

Toda a variável derivada indica no dicionário:

- variável(is)-base com o NOME EXATO usado no schema;
- regra de derivação;
- momento clínico;
- auditabilidade;
- justificação quando não for totalmente auditável.

Nunca marcar como auditável algo que não possa ser reconstruído exclusivamente

a partir das 162 variáveis exportadas.

Nunca usar aliases ou nomes inexistentes no schema dentro do dicionário ou das regras.

Exemplos proibidos: "LMP", "due date", "blood_pressure_week29", "PA_repetition_3T", "Preconception_performed" ou qualquer outro nome que não corresponda exatamente a uma coluna do dataset.

Variáveis diretamente observadas/geradas, e não derivadas, devem ser identificadas como:

"medição sintética direta / não derivada"

e NÃO devem receber falsas variáveis-base.

Em particular:

- repeated_third_trimester_blood_pressure_systolic e repeated_third_trimester_blood_pressure_diastolic são novas medições sintéticas condicionadas à trajetória tensional; não são uma transformação matemática da primeira tensão;

- third_trimester_24h_proteinuria_mg é uma medição laboratorial sintética direta; não é derivada da pressão arterial.

Derivações obrigatórias:

- bmi = visit1_weight_kg / (height_m^2)

- estimated_due_date = last_menstrual_period + 280 dias

- ultrasound_adjusted_estimated_due_date:
deve ser reconstruível conforme a regra específica da secção 5A abaixo.

- preterm_birth = 1 se e somente se gestational_age_at_delivery_weeks < 37

- macrosomia = 1 se e somente se birth_weight_g >= 4000

- fetal_growth_restriction = 1 se e somente se estimated_fetal_weight_third_trimester_percentile < 10,

quando esse percentil estiver disponível

- anemia_first_trimester = 1 se e somente se hemoglobin_first_trimester < 11

- anemia_second_trimester = 1 se e somente se hemoglobin_second_trimester < 10.5

- anemia_third_trimester = 1 se e somente se hemoglobin_third_trimester < 11, quando hemoglobin_third_trimester existir

- postpartum_anemia = 1 se e somente se postpartum_hemoglobin < 10

- EPDS_ge_12 = 1 se e somente se EPDS_score >= 12

- Goodwin_score_visit3/4/5/6/8 são inteiros;

risco:

0–2 = low;

3–6 = medium;

>=7 = high.

As hemoglobinas e EPDS_score têm de existir sempre que as respetivas flags forem

declaradas auditáveis.

As flags são calculadas sobre os valores com a precisão que será exportada,

depois do arredondamento, e não sobre medições latentes de maior precisão.

Uma base ausente implica flag ausente, salvo definição explícita diferente.

Em particular, hemoglobina ausente não significa anemia=0.

Os limiares de Hb na gravidez são os da OMS 2024: 11/10.5/11 g/dL nos três trimestres, respetivamente. A igualdade ao limiar não satisfaz o critério <. postpartum_anemia <10 é uma definição operacional do projeto: explicitar o momento da colheita e não a apresentar como definição universal do puerpério. A categoria Goodwin é reconstruível a partir do score; o score completo pode não ser reconstruível se faltarem componentes no schema. A extensão do score ao puerpério é uma escolha do desenho que requer justificação.

==========

5A. DATAÇÃO ECOGRÁFICA E EDD AJUSTADA — REGRA DURA NOVA

==========

A variável gestational_age_at_first_trimester_ultrasound_days deve representar uma medição ecográfica sintética. Não copiar sistematicamente a idade pelas datas, mas permitir concordância exata em algumas trajetórias.

Definir internamente:

calendar_gestational_age_at_ultrasound_days =
first_trimester_ultrasound_date - last_menstrual_period

Este valor interno NÃO é exportado como nova coluna, pois pode ser reconstruído pelas duas datas.

Gerar uma discrepância ecográfica sintética plausível, por exemplo entre -10 e +10 dias, com maior densidade perto de 0. Construir conjuntamente data, idade ecográfica e discrepância para que a idade exportada permaneça inteira entre

63 e 97 dias. Não gerar 98-104 dias por adição tardia de uma discrepância.

A variável exportada deve obedecer a:

gestational_age_at_first_trimester_ultrasound_days =

calendar_gestational_age_at_ultrasound_days

+ discrepância_ecográfica_sintética

Logo, a discrepância deve ser reconstruível no CSV:

discrepância_ecográfica_sintética =

gestational_age_at_first_trimester_ultrasound_days

- (first_trimester_ultrasound_date - last_menstrual_period)

Regra para ultrasound_adjusted_estimated_due_date:

- se ABS(discrepância_ecográfica_sintética) < 7 dias:

ultrasound_adjusted_estimated_due_date = estimated_due_date

- se ABS(discrepância_ecográfica_sintética) >= 7 dias:

ultrasound_adjusted_estimated_due_date =

first_trimester_ultrasound_date

+ (280 - gestational_age_at_first_trimester_ultrasound_days) dias

dating_confirmed_by_first_trimester_ultrasound deve ser coerente com a definição

semântica presente no dicionário e com a informação acima.

É PROIBIDO usar dating_confirmed_by_first_trimester_ultrasound como um driver oculto para alterar a EDD se a discrepância reconstruível não justificar essa alteração.
Usar esta mesma fórmula na construção de todas as trajetórias. A regra de redatação uniforme aos 7 dias é uma convenção operacional deste desenho, não uma recomendação clínica universal. Se a datação mudar durante a construção, recalcular idades, momentos observáveis e variáveis dependentes.

==========

6. DIABETES GESTACIONAL — OGTT — REGRA DURA

==========

Adotar explicitamente um perfil de rastreio para esta geração. Para manter o desenho original, usar o protocolo operacional baseado no consenso português de 2017, abaixo. Não o apresentar como reprodução integral de todas as recomendações atuais. Uma mudança de protocolo implica rever a definição das medições e documentar a edição escolhida, sem misturar critérios entre versões.

No perfil de compatibilidade, sem diabetes previamente conhecida:
- fasting_glucose <92 mg/dL: prever PTGO com 75 g às 24-28 semanas quando essa janela for atingida; a realização efetiva fica em OGTT_performed.
- 92 <= fasting_glucose <126: não realizar PTGO neste perfil; os três resultados ficam NA e representar referenciação para a consulta correspondente.
- fasting_glucose >=126: distinguir hiperglicemia compatível com diabetes na gravidez de DG; não inventar antecedente pré-gestacional a partir deste valor. Documentar a classificação e o circuito de cuidados nos metadados.

Quando OGTT_performed=1, exportar os três resultados e o momento real de

realização. No perfil escolhido, algum valor >=92/180/153 mg/dL às 0/1/2 h implica referenciação registada. Jejum >=126 ou 2 h >=200 requer distinção de diabetes na gravidez. Não contabilizar automaticamente esses casos como DG.

Quando OGTT_performed=0, os três resultados são NA. Se o parto impedir a realização da prova, não fabricar resultados nem um diagnóstico negativo.

Se pregestational_diabetes=1, representar diabetes conhecida antes da gravidez: não realizar PTGO de rastreio neste desenho. A referenciação depende do circuito assistencial documentado; não impor uma exclusividade clínica universal entre diabetes conhecida e acompanhamento numa consulta especializada.

Não criar uma nova coluna gestational_diabetes. Para a quota de DG, usar a classificação operacional documentada; não usar a referenciação como medida universal de doença. O circuito por defeito não inclui omissões deliberadas de referenciação quando há indicação representável. Só introduzir essas lacunas assistenciais se fizerem parte de um cenário explicitamente solicitado.

Gerar as glicemias primeiro, com distribuições e arredondamento plausíveis. Derivar depois a classificação e a conduta. Nunca concentrar casos exatamente em 92, 180 ou 153 para cumprir quotas.

Nota de âmbito: o consenso português de 2025 acrescenta ramos de confirmação precoce que exigem informação não presente neste schema, como uma segunda glicemia em determinados casos. Não afirmar que o perfil acima reproduz esses ramos sem os modelar e documentar separadamente.

==========

7. HIPERTENSÃO GESTACIONAL E PRÉ-ECLÂMPSIA — REGRA DURA

==========

Gerar a trajetória tensional antes das flags. Em todos os pares de PA, exigir valores numéricos finitos, positivos e sistólica estritamente superior à diastólica. Aplicar esta relação às medições iniciais, semana 29, repetição e pós-parto. Gerar os dois componentes conjuntamente; não trocar colunas nem normalizar PA elevada para esconder uma incoerência.

GERAÇÃO DA PA REPETIDA NESTE CENÁRIO:
Gerar repeated_third_trimester_blood_pressure_systolic entre 80 e 200 mmHg, inclusive, e repeated_third_trimester_blood_pressure_diastolic entre 40 e 130 mmHg, inclusive, mantendo sempre sistólica > diastólica. São limites operacionais do dicionário para este cenário, não intervalos de normalidade nem prova de que um valor exterior seja clinicamente impossível.

Não obter a repetição subtraindo automaticamente uma quantidade à primeira PA. Usar uma nova medição, condicionada ao nível tensional, variabilidade individual e eventual conduta já ocorrida, com ruído conjunto e dependência plausível entre componentes. A repetição pode subir ou descer; não impor descida universal nem converter hipertensão em PA normal.

Construir uma distribuição condicionada ao suporte operacional acima. Se uma amostra cair fora do suporte, voltar a amostrar o par de medições; não aplicar um piso de 80 às sistólicas nem um teto de 200, pois isso cria picos artificiais. Não colocar os 11 casos da geração anterior no valor 80 por substituição.

Preservar medições elevadas e em faixa grave dentro do âmbito do cenário,

sem empurrar casos para 140/90 ou 160/110. Derivar as flags hipertensivas e a conduta só depois das duas medições finais, para que qualquer mudança da PA repetida se reflita também na classificação e na trajetória subsequente.
Se o objetivo passar a incluir hipotensão sistólica <80 ou valores >200, isso exige um cenário clínico explicitamente alargado e documentado; não introduzir esses casos por um ruído não controlado neste perfil de geração.

CONTROLO OBRIGATÓRIO DE SUPORTE DA PA REPETIDA — CORREÇÃO V8.1:
- Antes de aceitar cada trajetória, verificar o par exportável de PA repetida, após aplicação da precisão/arredondamento definidos no dicionário: 80 <= repeated_third_trimester_blood_pressure_systolic <= 200; 40 <= repeated_third_trimester_blood_pressure_diastolic <= 130; repeated_third_trimester_blood_pressure_systolic > repeated_third_trimester_blood_pressure_diastolic.
- Estes testes só são aplicáveis quando a medição é temporalmente observável. Se o parto ocorrer antes de 29 semanas, ambas as medições permanecem NA, conforme a regra de truncagem da secção 10. NA estrutural não é falha.
- Gerar o par através de uma distribuição conjunta CONDICIONADA ao suporte admissível, que permita correlação clínica, variabilidade e tanto subidas como descidas relativamente à primeira medição. Não gerar primeiro uma distribuição irrestrita e depois recortar, limitar ou substituir apenas o valor inválido por 80 ou 200. Não transformar valores acima de 200 em 200.
- Se uma proposta de par cair fora do suporte, rejeitar a proposta e voltar a amostrar CONJUNTAMENTE sistólica e diastólica a partir da distribuição condicionada à trajetória. Se não for possível obter um par plausível sem contradizer a evolução clínica (por exemplo, uma trajetória que exige persistentemente valores além do âmbito escolhido), rejeitar e regenerar a TRAJETÓRIA COMPLETA, incluindo fatores relacionados, e não apenas uma

medição isolada.

- Depois de fixar o par final, derivar novamente gestational_hypertension, preeclampsia e quaisquer outras flags, intervenções e outcomes que dependam dele. Nunca conservar diagnósticos calculados sobre um par rejeitado.
- Na verificação pré-exportação, exigir ZERO observações presentes fora deste suporte nas 5000 trajetórias. Se houver uma única violação, NÃO declarar conformidade nem entregar o CSV como versão final: regenerar a trajetória afetada e todas as suas dependências, preservando o schema de 162 colunas.
- Esta exigência é uma condição de consistência com o cenário escolhido, não uma afirmação de que valores clínicos fora destes limites sejam impossíveis.

Uma medição com sistólica >=140 OU diastólica >=90 mmHg é elevada; >=160 OU >=110 é uma medição em faixa grave. Isso não equivale, isoladamente, a confirmar hipertensão persistente. No perfil operacional deste desenho, usar as medições após 20 semanas e uma repetição coerente, com momento de colheita descrito. Não usar PA pós-parto para inventar início antenatal.

O cenário por defeito não modela hipertensão crónica ou PE sobreposta, porque o schema não as discrimina adequadamente. Declarar esta restrição do desenho. Não concluir clinicamente ausência de doença crónica só porque uma PA inicial é normal. Casos que dependam de episódios não exportados são parcialmente auditáveis, e não devem ser apresentados como integralmente reconstruíveis.

Para o fenótipo operacional, exigir PA elevada confirmada pelos pares disponíveis. A média das sistólicas deve ser >=140 OU a média das diastólicas >=90; não combinar componentes alternadamente elevados com médias normais como se isso bastasse para a confirmação. Datas e contexto da repetição ficam explícitos

nos metadados quando não existem no schema.

Com confirmação operacional e medições disponíveis:
- third_trimester_24h_proteinuria_mg <300 -> gestational_hypertension=1, preeclampsia=0, no perfil simplificado sem outras causas;
- third_trimester_24h_proteinuria_mg >=300 -> preeclampsia=1, gestational_hypertension=0.

Sem medições suficientes, não preencher uma flag negativa apenas para completar a linha. Os campos representam o estado final do perfil escolhido; pode haver evolução de hipertensão gestacional para PE antes desse estado.

O perfil cobre sobretudo a apresentação proteinúrica. A PE clínica também pode envolver disfunção materna ou uteroplacentária sem proteinúria; não alegar que a fórmula cobre todas as formas. PE precoce não deixa de existir clinicamente por faltar uma medição de week29: não inventar essa medição em quem pariu antes; declarar a limitação do caso ou do âmbito gerado.

Permitir subida progressiva e heterogeneidade. Evitar concentrações artificiais em 140/90 ou 300 mg. PA repetida é nova medição e proteinúria é medição laboratorial direta, não derivação matemática da primeira PA.

==========

8. PESO MATERNO E GANHO PONDERAL — REGRA REVISTA

==========

Registar peso longitudinal:
visit1_weight_kg ... visit8_weight_kg

e, quando aplicável:

weight_4_months_postpartum_kg

weight_6_months_postpartum_kg.

Para gravidezes de termo, manter como referência de ganho gestacional total por BMI basal:

- bmi < 18.5 -> 12.5–18 kg
- 18.5 <= bmi <25 -> 11.5–16 kg
- 25 <= bmi <30 -> 7–11.5 kg
- bmi >=30 -> 5–9 kg

Estas faixas são ALVOS PARA TRAJETÓRIAS QUE ATINGEM O TERMO/FINAL DA GESTAÇÃO e NÃO devem ser impostas integralmente a uma gravidez que termina precocemente.

No 1.o trimestre:

- ganho acumulado esperado aproximadamente 0.5–2 kg, com variabilidade individual.

Depois:

- ganho progressivo e não linear;
- permitir variação fisiológica entre consultas;
- evitar sequências rigidamente lineares;
- pequenas oscilações são permitidas desde que a trajetória global seja plausível.

REGRA OPERACIONAL PARA PRÉ-TERMO:

1. Determinar a última consulta antenatal efetivamente realizada.

2. Determinar a idade gestacional dessa consulta através de:

(last_antenatal_visit_date - origem_gestacional) / 7.

Ambos os nomes são expressões internas, não novas colunas.

3. O ganho esperado nessa data deve corresponder apenas à fração da gestação já

decorrida.

4. NÃO exigir a uma grávida que termina a gravidez antes do termo que já tenha

atingido o intervalo total previsto para 40 semanas.

Método interno recomendado de geração:

- gerar primeiro um target_term_weight_gain individual dentro da faixa

correspondente ao BMI;

- gerar ganho no 1.o trimestre aproximadamente entre 0.5 e 2 kg;

- fazer o ganho restante acumular progressivamente entre o fim do 1.o trimestre e

cerca de 40 semanas;

- se a trajetória terminar antes, usar apenas o ganho acumulado esperado até à

última consulta realizada.

O target_term_weight_gain é uma variável LATENTE e NÃO é exportada.

total_weight_gain =

peso da ÚLTIMA consulta antenatal efetivamente realizada

- visit1_weight_kg.

Nas gravidezes de termo, corresponde habitualmente a:

visit7_weight_kg - visit1_weight_kg.

Nas pré-termo:

usar a última visitK_weight_kg não-NA anterior ao parto.

Nunca calcular total_weight_gain a partir de uma consulta a NA nem de uma consulta posterior ao parto.

CONSTRUÇÃO DO GANHO PONDERAL:

- para gestações de termo, usar as faixas como referências de geração, não como limites que todas as pessoas têm de cumprir;
- para pré-termo, verificar coerência do ganho acumulado com a idade gestacional da última consulta, e NÃO aplicar cegamente as faixas de termo;
- a média de total_weight_gain deve aumentar de forma geral à medida que aumenta a idade gestacional no parto/última consulta.

postpartum_weight_loss =
peso da última consulta antenatal realizada
- visit8_weight_kg.

Gerar a diferença ponderal coerente com as datas e a trajetória puerperal. Não impor perda universal de 5–8 kg; podem existir outras magnitudes ou aumento de peso. Se faltar alguma base, a diferença fica NA. O IMC de visit1 é uma aproximação ao IMC pré-gestacional apenas quando essa aproximação estiver assumida; o ganho desde visit1 não representa necessariamente todo o ganho desde a pré-conceção.

==========

9. RASTREIOS, SUPLEMENTAÇÃO E OUTRAS VARIÁVEIS

==========

- VIH:

HIV1_HIV2_antibodies_first_trimester / _third_trimester:

normal = negativo.

- Rubéola:

1.o trimestre;

se não imune, repetir no 2.o.

- Toxoplasmose:

1.o trimestre;

se negativo, repetir no 2.o;

se ainda negativo, repetir no 3.o.

- HBsAg:

1.o trimestre;

HBsAg_third_trimester quando indicado.

Se não vacinada e negativo, repetir no 3.o.

- Ácido fólico:

Escolher e documentar o conjunto de indicações de dose elevada antes da geração. Não fazer OR indiscriminado de todas as doenças, fármacos e IMC como se as indicações fossem universais e iguais entre fontes.

Gerar high_risk_folic_acid_indication a partir das indicações selecionadas. Filho anterior com DTN ou história familiar de DTN implica indicação de dose elevada neste cenário. Outras indicações seguem a fonte e o contexto adotados.

Se folic_acid_started=1:

- high_risk_folic_acid_indication=1 -> folic_acid_dose=5000 microgramas/dia;

- high_risk_folic_acid_indication=0 -> folic_acid_dose=400 microgramas/dia.
Se folic_acid_started=0, folic_acid_dose=NA, mantendo a indicação verdadeira.
Nunca representar 5 mg como 5 microgramas; 5 mg =5000 microgramas.

Permitir aproximadamente 5–10% de não adesão, por início ausente/interrupção conforme a semântica dos campos. Não simular não adesão trocando uma dose prescrita de 5000 por 400 quando a indicação é de dose elevada.

- Iodeto de potássio:
suplementação ao longo de gravidez/puerpério/aleitamento;
aproximadamente 5–10% de não adesão.

- BCF:
fetal_heartbeat_present_visit2..visit7 com dinâmica longitudinal.
Após viabilidade, uma gravidez evolutiva não deve apresentar desaparecimentos e reaparecimentos arbitrários sem evento clínico correspondente.

- Aleitamento:
Gerar transições probabilísticas entre os estados canónicos do dicionário.
Não proibir formula/artificial -> mixed/exclusive como impossibilidade clínica: pode existir relactação. Um cenário que não inclua relactação deve dizê-lo como restrição do desenho. Distinguir alimentação atual de exclusividade desde o nascimento e explicitar o significado da categoria aos 6 meses.

- Altura uterina no puerpério:
uterine_fundal_height_postpartum é cm acima da sínfise púbica; 0 significa não palpável. No desenho do dicionário, usar 0–8 e o momento de observação puerperal explicitado. Gerar em função da recuperação e do tempo desde o

parto, não de uma distribuição antenatal ou de outra escala de medição.
Não gerar valores 8–14 para depois lhes aplicar um teto de 8. Se uma situação clínica exigir outra convenção, documentar a incompatibilidade de âmbito.

- Saúde mental e referenciação:
No cenário assistencial por defeito, EPDS_score>=12 implica referred_to_mental_health=1. Uma referenciação com total inferior a 12 pode ter outras razões. A escala é rastreio; não confirma depressão. O item 10 não está no schema e não pode ser reconstruído a partir do total. Ausência de referenciação apesar de indicação só entra se esse cenário de lacuna de cuidados tiver sido explicitamente solicitado.

==========

10. PARTO PRÉ-TERMO — ESPECTRO, MECANISMO E TRUNCAGEM — REGRAS DURAS

==========

ESPECTRO DE GRAVIDADE dentro dos pré-termos, com variabilidade contínua:

- tardio: 34 a <37 semanas -> ~70%
- moderado: 32 a <34 -> ~12%
- muito pré-termo: 28 a <32 -> ~12%
- extremo: <28 -> ~6%

Estas proporções são aproximadas, não targets que justifiquem manipular diretamente gestational_age_at_delivery_weeks para valores de fronteira.

MECANISMO:
o excesso de pré-termos NÃO se obtém aumentando uniformemente a

probabilidade em toda a população.

Deve emergir de causas e fatores de risco:

- taxa basal espontânea em pessoas sem patologia-alvo;
- pré-eclâmpsia associa-se a maior probabilidade de parto pré-termo; o RR de aproximadamente 4–5x, se usado, é parâmetro de cenário, não lei clínica;
- pré-termo associado a pré-eclâmpsia é frequentemente indicado: maior probabilidade de labor_induction = 1 e/ou delivery_type = cesarean; concentrado sobretudo entre 30–36 semanas;
- anemia pode associar-se a maior probabilidade de parto pré-termo; o RR de aproximadamente 1.5–2x, se usado, é parâmetro do cenário. Não usar uma Hb de terceiro trimestre ainda não observada para causar um parto anterior;
- não deduzir o mecanismo de um parto muito precoce da disponibilidade de medições week29. Modelar o mecanismo e declarar as limitações observacionais.

Permitir:

- pré-eclâmpsia a termo;
- parto pré-termo sem pré-eclâmpsia;
- anemia sem parto pré-termo;
- parto pré-termo sem anemia.

preterm_birth resulta exclusivamente de:

gestational_age_at_delivery_weeks < 37.

TRUNCAGEM DO CALENDÁRIO DE CONSULTAS:

Uma consulta só existe se a gravidez ainda decorria na respetiva janela:

visit2 ≈16 semanas

visit3 ≈20–22

visit4 ≈28–30

visit5 ≈32

visit6 ≈34–36

visit7 ≈36–40

Se o parto for antes da janela, ficam a NA:

visitK_date

visitK_weight_kg

potassium_iodide_supplementation_visitK

fetal_heartbeat_present_visitK

Goodwin_score_visitK

Goodwin_risk_visitK

quando aplicável.

Exames do 3.o trimestre:

- parto <29 semanas:

blood_pressure_week29_systolic = NA

blood_pressure_week29_diastolic = NA

repeated_third_trimester_blood_pressure_systolic = NA

repeated_third_trimester_blood_pressure_diastolic = NA

third_trimester_24h_proteinuria_mg = NA

- parto <28 semanas:

hemoglobin_third_trimester = NA

anemia_third_trimester = NA

e deve ser documentado que esta flag deixa de ser auditável/não observável nesse caso.

- ecografia de crescimento do 3.o trimestre não atingida:

estimated_fetal_weight_third_trimester = NA

estimated_fetal_weight_third_trimester_percentile = NA

abdominal_circumference_third_trimester = NA

head_circumference_third_trimester = NA

femur_length_third_trimester = NA

- parto <35 semanas:

GBS_result = NA

- janela OGTT não atingida:

OGTT_performed = 0

OGTT_fasting_glucose = NA

OGTT_1h_glucose = NA

OGTT_2h_glucose = NA

Consequências:

- total_weight_gain usa a última consulta realizada;

- fetal_growth_restriction só pode ser diagnosticado quando o percentil existir;

- se o percentil não existir por parto muito precoce, não inventar diagnóstico observável;

- nenhuma data antenatal pode ser posterior a delivery_date;

- a percentagem de consultas em falta deve crescer à medida que a idade gestacional ao parto diminui.

O calendário é contado desde origem_gestacional. A primeira consulta é um momento pré-natal definido no desenho; se se escolher acesso atempado segundo
a norma DGS atualizada em 2026, ocorre até 9 semanas e 6 dias. Os momentos visit2–visit7 acima são observações selecionadas, não necessariamente todas as consultas prestadas. Não impor em simultâneo intervalos universais de 4–6 semanas incompatíveis com essas janelas. Não eliminar uma complicação para fazer caber a trajetória num calendário de gravidez de baixo risco.

Uma visita só tem data e medições quando foi efetivamente realizada antes do parto. A ausência de uma visita intermédia não impede automaticamente que uma visita posterior aconteça. Os NA por truncagem não são negativos clínicos. As proporções de gravidade anteriores são parâmetros de desenho aproximados, nunca frequências obrigatórias da prática clínica.

==========

11. MACROSSOMIA E CRESCIMENTO FETAL

==========

macrosomia deve emergir de:

- características maternas;
- bmi elevado;
- eventual diabetes gestacional;
- trajetória de crescimento fetal;
- idade gestacional ao parto;
- peso ao nascer.

Diagnóstico:

macrosomia = 1 se e somente se birth_weight_g >= 4000.

birth_weight_g deve ser coerente com gestational_age_at_delivery_weeks:

- em média aumenta com a idade gestacional;
- pré-termo deve apresentar peso proporcionalmente menor;
- macrossomia deve ficar praticamente restrita a partos >=37 semanas.

MODELO DO PESO AO NASCER, INCLUINDO PREMATUROS EXTREMOS:

Escolher uma referência publicada de tamanho ao nascer com cobertura da idade gestacional efetivamente gerada. Identificar edição, população, unidade, equações/tabelas e intervalo de aplicação. Como fontes de partida, consultar os padrões INTERGROWTH-21st de tamanho ao nascer e a referência específica para muito pré-termo; não aplicar uma única tabela fora do seu âmbito.
Não confundir uma curva fetal antenatal com uma referência de peso ao nascer.

Gerar peso a partir da distribuição condicional à idade gestacional e ao perfil de crescimento, usando a parametrização publicada ou uma aproximação cuja fórmula e erro de aproximação sejam explicitados. Não usar como modelo único para todo o espectro uma reta do tipo peso de termo + constante por semana, com ruído aditivo de desvio fixo. Esse mecanismo pode produzir massas extremamente baixas nos prematuros por extrapolação e não deve ser mantido.

Quando a referência for específica por sexo e o schema não contiver esse campo, gerar o sexo neonatal apenas como variável auxiliar, mantê-lo fixo na trajetória e registá-lo numa tabela metodológica separada por patient_id.
Não criar uma 163.ª coluna nem alegar que esse ajuste pode ser reconstruído apenas a partir do CSV principal. Alternativamente, usar uma referência sem

estratificação por sexo, se adequada e explicitamente documentada.

Se a idade pretendida estiver fora da cobertura da fonte, selecionar uma referência aplicável ou declarar e resolver a incompatibilidade do desenho; não extrapolar silenciosamente. Transições entre referências devem manter uma distribuição coerente, sem degraus artificiais junto da mudança de tabela.

Conservar dependência probabilística entre crescimento fetal e massa neonatal, permitindo variação entre pessoas e erro das medições. Modelar o intervalo entre a última ecografia e o parto; a estimativa antenatal não é o peso real ao nascer nem deve coincidir sempre com ele. A classificação de pequeno para a idade gestacional ao nascer não é automaticamente a flag FGR antenatal.

Neste cenário, a massa neonatal exportada deve também respeitar o domínio operacional 300–6000 g do dicionário. Esse intervalo não é um limite universal de viabilidade ou impossibilidade clínica. O suporte deve ser aplicado de modo condicional à idade e ao cenário, não como único critério de plausibilidade: um valor acima de 300 g pode continuar desajustado à idade gestacional.

Se uma amostra for incompatível com a distribuição, o domínio ou a trajetória, gerar novamente o componente crescimento/nascimento e as suas dependências.
Não substituir 43 g, 182 g ou outro extremo por 300 g; não aplicar um piso ou teto artificial nem descartar o caso sem recompor a coorte. Recalcular peso, macrossomia, variáveis de crescimento afetadas e composição do cenário.

Numa coorte enriquecida, valores fora dos percentis centrais são esperados. Não limitar todos os nascimentos ao intervalo P3–P97 nem transformar uma

referência de crescimento saudável numa exigência de normalidade para todos. Representar caudas de crescimento baixo/elevado com um mecanismo explícito, preservando os fenótipos e a heterogeneidade. Não inventar limites de z-score universais; justificar qualquer truncagem como escolha metodológica.

Gerar também macrossomia sem diabetes gestacional quando plausível.

fetal_growth_restriction:
- associado probabilisticamente a menor estimated_fetal_weight_third_trimester;
- associado probabilisticamente a menor birth_weight_g;
- não pode coexistir com um peso neonatal elevado incoerente.

REGRA DURA DE EXCLUSÃO PARA EVITAR A INCOERÊNCIA OBSERVADA:
- se fetal_growth_restriction = 1, então macrosomia = 0;
- se macrosomia = 1, então fetal_growth_restriction = 0;
- se fetal_growth_restriction = 1, birth_weight_g deve ser <4000 g.

Não gerar trajetórias com:
estimated_fetal_weight_third_trimester_percentile <10
e simultaneamente birth_weight_g >=4000.

Para FGR, a trajetória de crescimento do 3.o trimestre e o peso ao nascer devem apontar globalmente na mesma direção clínica.

ANTI-HEAPING DE MACROSSOMIA:
não usar 4000 g como valor de correção.
Casos com macrosomia devem ocupar uma distribuição acima de 4000 g e casos

não macrossómicos uma distribuição abaixo, com continuidade plausível em torno

do cut-off.

PERCENTIL E FLAG DE CRESCIMENTO:

Gerar biometria, estimativa de peso e percentil com uma curva e idade do exame documentadas. Exportar o percentil como inteiro de 1 a 99 conforme o dicionário. Se existir um percentil contínuo interno, definir a sua representação inteira antes de calcular a flag. Nunca exportar 5.38 ou 73.85 nesta coluna.

CADEIA DE CRESCIMENTO FUNDAMENTADA:

Definir primeiro a idade gestacional exata da observação, a convenção de cada biometria e as unidades (por exemplo, mm para perímetros/comprimentos quando

assim definido no dicionário). Gerar conjuntamente as medidas com correlações e variabilidade plausíveis, não cada uma como sorteio independente sem relação com o feto representado. Não misturar mm e cm em fórmulas.

Derivar estimated_fetal_weight_third_trimester a partir das biometrias disponíveis com uma fórmula publicada aplicável, identificando os seus argumentos, coeficientes, unidades e intervalo de utilização. Uma opção metodológica é uma fórmula de Hadlock que use apenas as medidas efetivamente presentes; não inventar um BPD de terceiro trimestre só para preencher uma fórmula que o exija. O conjunto de variáveis, a fórmula de estimativa e a curva de percentis têm de ser compatíveis. Usar os valores exportados na derivação, com tolerância de arredondamento explicitada, para que não haja resultados contraditórios.

Calcular o percentil contínuo a partir desse mesmo peso estimado e da idade gestacional na observação, usando uma curva publicada e identificada cujo

âmbito cubra a medição. Não produzir percentil como Phi(z)*100 de uma normal sintética e apresentá-lo como percentil clínico. Não escolher um percentil por sorteio e gerar depois um peso de uma distribuição incompatível.

A distribuição usada para enriquecer a coorte pode ser diferente da população de referência; a correspondência entre peso, idade e percentil continua a usar a curva escolhida. Uma fonte clínica não valida automaticamente a distribuição de amostragem do gerador. Se não for possível implementar a fórmula ou obter os coeficientes/tabelas necessários, declarar o bloqueio desse componente; não substituir silenciosamente a referência por uma função inventada.

Guardar a idade/data efetiva da ecografia no registo metodológico auxiliar se não houver coluna própria no schema. A data de visit5, ou de outra visita próxima, não deve ser apresentada como prova da data real da ecografia.

REPRESENTAÇÃO INTEIRA DO PERCENTIL:
Descrever a regra de quantização. Por defeito neste desenho, arredondar o percentil contínuo ao inteiro mais próximo (metades para cima), preservando o valor contínuo nos metadados auxiliares. O domínio exportado continua 1–99. Se a curva produzir valores que, após essa quantização, resultem em 0 ou 100, regerar o componente de crescimento dentro do âmbito representável; não os recortar para 1/99 nem deslocar sistematicamente casos para os extremos. Documentar que esta restrição de representação pode excluir fenótipos das caudas e que o CSV não retém toda a precisão do percentil clínico contínuo.

Calcular fetal_growth_restriction sobre o percentil que será exportado:
1–9 ->1; 10–99 ->0; observação ausente ->NA. Não manter uma flag calculada antes do arredondamento que deixe de corresponder ao inteiro exportado.

Se o arredondamento afetar a trajetória ou os objetivos de composição, gerar uma trajetória completa coerente; não empurrar o percentil para 9 ou 10.

O limiar apenas de EFW<10 é uma definição operacional simplificada deste campo, não a totalidade dos critérios clínicos possíveis de FGR. A exclusão FGR × macrossomia acima é uma restrição deste cenário de geração, não uma impossibilidade universal entre observações realizadas em momentos diferentes.

SIGNIFICADO DE second_trimester_biometry:
Este nome agregado não define, por si só, uma medição clínica, unidade ou fórmula. Consultar a definição original e identificar o que representa antes de gerar valores. Não o redefinir como massa fetal agregada em gramas, média de comprimentos ou score composto apenas para preencher a coluna.

Se a fonte identificar uma medida escalar concreta, usar exatamente esse significado, unidade e relação com as outras biometrias. Se descrever um conjunto de medidas já exportadas nas colunas específicas, documentar a redundância e resolver a representação desse campo agregado sem inventar um novo significado. Não eliminar nem renomear a coluna.

Se os materiais disponíveis não resolverem a ambiguidade, conservar a coluna como NA e identificar SEMÂNTICA PENDENTE no dicionário. Esta ausência é uma lacuna documental, não ausência de exame nem resultado normal; não a disfarçar como missing aleatório de 3–7%. Indicar que a definição requer decisão dos autores/profissionais antes de tratar esta variável como pronta para uso.
As biometrias específicas com significado conhecido podem ser geradas segundo as suas definições. Não alegar que todas as 162 variáveis têm interpretação clínica resolvida enquanto este ponto permanecer pendente.

==========

12. ASSOCIAÇÕES EPIDEMIOLÓGICAS — PROBABILÍSTICAS, NUNCA DETERMINÍSTICAS

==========

- bmi elevado -> maior probabilidade de diabetes gestacional, hipertensão, pré-eclâmpsia, macrossomia e cesariana;
- idade materna >=35 -> maior probabilidade de diabetes gestacional, hipertensão e cesariana;
- diabetes gestacional -> maior probabilidade de indução, macrossomia e cesariana;
- pré-eclâmpsia -> maior probabilidade de parto pré-termo;
- anemia -> maior probabilidade de parto pré-termo;
- fetal_growth_restriction -> menor peso ao nascer.

Devem existir exemplos positivos e negativos em todos os grupos:

- GDM sem macrossomia;
- macrossomia sem GDM;
- PE a termo;
- pré-termo sem PE;
- obesas sem complicações;
- bmi normal com complicações;
- anemia sem pré-termo;
- pré-termo sem anemia.

Nenhuma destas associações deve tornar-se determinística.

==========

13. COMPOSIÇÃO DA COORTE E ENRIQUECIMENTO

==========

Requisitos de composição mínimos, ajustáveis pelo investigador.

NÃO são prevalências reais.

N_TOTAL = 5000

MIN_GDM = 700 (~14%)

MIN_HIPERTENSAO_GESTACIONAL = 500 (~10%)

MIN_PREECLAMPSIA = 350 (~7%)

MIN_MACROSSOMIA = 650 (~13%)

MIN_PARTO_PRETERMO = 750 (~15%)

MIN_fetal_growth_restriction = 500 (~10%)

Manter pelo menos 1500 das 5000 trajetórias (>=30%) SEM nenhuma patologia-alvo,

segundo a definição operacional explícita abaixo.

DEFINIÇÃO DO GRUPO DE CONTROLO:

Um controlo é uma trajetória sem DG segundo o protocolo escolhido, sem diabetes pré-gestacional, sem os fenótipos operacionais de hipertensão gestacional e PE, sem macrossomia, sem prematuridade e sem o fenótipo FGR. Isto não significa ausência de todos os fatores de risco ou de todas as doenças: permitir idade >=35, IMC fora da referência, anemia e outras características

não incluídas nas patologias-alvo, quando coerentes com a trajetória.

No perfil de rastreio da secção 6, para integrar o grupo de controlo:
- pregestational_diabetes=0 e fasting_glucose <92 mg/dL;
- PTGO efetivamente realizada na janela adequada, OGTT_performed=1 e três componentes observados: jejum <92, 1 h <180 e 2 h <153 mg/dL;
- gestational_hypertension=0 e preeclampsia=0, com medições necessárias presentes e coerentes com a definição operacional da secção 7;
- macrosomia=0 e birth_weight_g <4000;
- preterm_birth=0 e gestational_age_at_delivery_weeks >=37;
- fetal_growth_restriction=0 e percentil fetal exportado >=10, observado.

referred_to_gestational_diabetes_clinic=0, isoladamente, NÃO identifica um controlo nem demonstra ausência de DG. Esta coluna continua a representar referenciação; não a usar para substituir os critérios glicémicos acima.
Valores desconhecidos ou exames não realizados não contam como negativos. Um caso com informação insuficiente para alguma condição-alvo não pertence ao grupo de controlo demonstrável por estas variáveis.

CONSTRUÇÃO DA COMPOSIÇÃO:
Reservar na amostragem pelo menos 1500 trajetórias candidatas a controlo e gerar os restantes perfis com sobreposição plausível das condições-alvo. A designação candidata não decide as flags: a pertença final emerge dos valores e das regras acima. Se uma candidata desenvolver uma condição-alvo ou ficar sem observação essencial, passa a não controlo ou indeterminada; gerar outra trajetória completa em substituição para manter os >=1500 controlos.

Não criar um conjunto de controlos perfeitamente idênticos, sem fatores de

risco ou com todas as medições centradas num único valor normal. Não retirar complicações aos outros grupos nem reduzir os mínimos de enriquecimento para satisfazer esta proporção. Não introduzir missing aleatório em bases essenciais de um controlo e continuar a contá-lo como demonstravelmente negativo.

Na tabela descritiva, apresentar N_CONTROL= número de trajetórias que satisfazem
todos os critérios, a sua percentagem sobre 5000 e o número de trajetórias indeterminadas por informação insuficiente. O grupo de controlo é distinto do grupo sem referenciação. Não acrescentar uma coluna de controlo ao CSV: documentar a regra e, se necessário, a pertença por patient_id numa tabela auxiliar.

Permitir sobreposição clinicamente plausível entre patologias.

Não somar os mínimos como grupos mutuamente exclusivos.

Se algum mínimo não for atingido:
- gerar trajetórias adicionais ou substituir trajetórias completas;
- recalcular todas as medições e outcomes da trajetória;
- NÃO alterar artificialmente flags;
- NÃO mover uma medição para exatamente o cut-off;
- NÃO alterar apenas a variável diagnóstica final.

==========

14. VARIABILIDADE E ANTI-ARTEFACTOS

==========

- 3–7% de missing estruturado apenas em variáveis não críticas;
- 5–10% de não adesão à suplementação quando aplicável;
- variação fisiológica e heterogeneidade de perfis;
- pequenas inconsistências administrativas plausíveis apenas se não violarem regras duras;
- não introduzir missing que torne impossível auditar uma flag declarada auditável;
- evitar perfis clínicos perfeitos;
- evitar relações determinísticas artificiais.

ANTI-HEAPING / ANTI-CUTOFF-ARTEFACT:

Para cada variável contínua usada num cut-off diagnóstico:

fasting_glucose

OGTT_fasting_glucose

OGTT_1h_glucose

OGTT_2h_glucose

blood_pressure_week29_systolic

blood_pressure_week29_diastolic

repeated_third_trimester_blood_pressure_systolic

repeated_third_trimester_blood_pressure_diastolic

third_trimester_24h_proteinuria_mg

estimated_fetal_weight_third_trimester_percentile

birth_weight_g

hemoglobinas

EPDS_score

deve existir uma distribuição plausível em torno dos limiares.

Não deve existir acumulação artificial exatamente no cut-off.

Regra de controlo:

- valores exatamente no cut-off podem existir por arredondamento natural;

- porém não devem constituir uma fração desproporcionada dos casos positivos;

- se o número exatamente no cut-off produzir um pico evidente quando comparado

com valores imediatamente abaixo e acima, regenerar esses casos;

- considerar a resolução e a distribuição de cada variável; não impor uma percentagem universal de casos exatamente no limiar, sobretudo a scores discretos como EPDS e percentis exportados como inteiros;

- quotas de patologias nunca podem ser satisfeitas através de concentração no valor-limite.

==========

15. DICIONÁRIO DE DADOS — REGRAS DE QUALIDADE DOCUMENTAL

==========

O dicionário expandido deve ter uma linha por cada uma das 162 variáveis e usar SEMPRE os nomes exatos do schema.

Para cada variável indicar:

1. nome;

2. tipo semântico;

3. tipo exportado;

4. codificação;

5. valores permitidos / unidade / intervalo esperado;

6. momento de colheita;

7. valor esperado;

8. variáveis-base;

9. regra de derivação;

10. auditabilidade e respetiva justificação.

Regras:

- variáveis derivadas: listar apenas variáveis-base que realmente existem no CSV;

- variáveis diretamente medidas/geradas: "variáveis-base = não aplicável";

- não inventar aliases;

- não declarar uma variável direta como derivada de outra apenas por correlação clínica;

- repeated BP é nova medição, não derivação matemática;

- proteinúria de 24 h é medição direta, não derivação da pressão;

- toda a regra declarada auditável deve ser recalculável a partir do CSV.

O dicionário cita apenas nomes existentes no conjunto oficial das 162 colunas. Fórmulas auxiliares ficam descritas como expressões internas, sem serem apresentadas como colunas exportadas. Não inventar bases clínicas ausentes.

==========

16. CONSTRUÇÃO FINAL — COERÊNCIA DAS TRAJETÓRIAS

==========

Construir todas as variáveis dependentes a partir das mesmas medições, datas e convenções. A coerência é uma propriedade da geração, não um relatório de um programa externo a integrar neste pedido.

Na ordem de construção:

- estabelecer a DUM, ecografia e EDD ajustada;
- usar uma origem temporal única para eventos e duração gestacional;
- gerar medições com unidades, tipos e precisão definidos;
- representar ausências estruturais antes de derivar flags;
- calcular flags apenas a partir dos valores que serão exportados;
- gerar conduta consistente com o cenário e a informação já observada;
- obter parto, puerpério e seguimento coerentes com os eventos;
- calcular ganhos/perdas a partir dos pesos realmente disponíveis;
- aplicar o enriquecimento por seleção de trajetórias completas.
- executar verificação bloqueante do suporte da PA repetida definido na secção 7, sobre os valores efetivamente exportáveis e após arredondamento; uma violação obriga a regenerar a trajetória e recalcular dependências.

Não escrever flags independentes das suas bases. Não inventar medições posteriores ao parto, doses de outra unidade ou valores de outra escala. Valores patológicos e fatores de risco são esperados nesta coorte e não devem ser convertidos em valores normais para produzir trajetórias perfeitas.

Se duas instruções forem incompatíveis, explicitar a incompatibilidade e a decisão metodológica; não esconder o conflito nem inventar conformidade. A ausência de informação que o schema não representa deve permanecer declarada como limitação.

==========

17. OUTPUT OBRIGATÓRIO

==========

Entregar:

1. Dataset sintético em CSV ou XLSX, 5000 ×162, com patient_id na primeira coluna e sem colunas adicionais.

2. Dicionário expandido das 162 variáveis: significado, tipo, codificação, categorias, unidades, precisão, momento, bases, derivação e auditabilidade.

3. Descrição das regras e do método de geração, incluindo a seed quando a geração for realizada por código e os parâmetros de enriquecimento.

4. Assunções clínicas e operacionais, com fontes, edição e limitações das definições simplificadas. Distinguir recomendações médicas de escolhas do desenho, como proporções, exclusões e convenções de representação.

5. Tabela descritiva de representação das condições-alvo, com números, percentagens e denominadores observáveis; tabela de coocorrências.

6. Limitações de utilização e de reconstrução das variáveis.

Este pedido não inclui relatórios de avaliação independente, resultados de testes de outro programa nem certificados de aprovação clínica. Não afirmar que essa etapa já foi realizada. Os documentos de geração acompanham o dataset, sem substituir a análise que será feita posteriormente.

==========

18. LIMITAÇÕES E TRANSPARÊNCIA

==========

Declarar explicitamente:

- dataset totalmente sintético, sem ligação a pacientes reais;
- população deliberadamente enriquecida;
- proporções NÃO representam prevalências reais;
- esta coorte deve ser descrita como uma "risk-enriched synthetic obstetric cohort"

ou equivalente, e não como uma população representativa de gravidez de baixo risco;

- destinado a investigação metodológica, ML, IA Generativa e Explainable AI;
- não substitui dados epidemiológicos reais;
- não se destina a decisão clínica;
- qualquer regra ou variável não auditável tem de ser identificada;
- modelação de pré-eclâmpsia simplificada;
- crescimento fetal e biometria são aproximações sintéticas;
- não alegar validade clínica/epidemiológica para aspetos que o schema não permite verificar.

Referências que enquadram as escolhas descritas, sem transformar este prompt num processo de avaliação externa:

- OMS, Guideline on haemoglobin cutoffs, 2024, tabela 2: Hb na gravidez.
  https://www.who.int/publications/i/item/9789240088542
- Consenso português de diabetes gestacional, 2017: perfil histórico de
  compatibilidade explicitamente adotado na secção 6.
  https://www.dgs.pt/programa-nacional-para-a-diabetes/documentos-e-comunicacoes/consenso-diabetes-gestacional-atualizacao-2017-pdf.aspx
- Consenso Diabetes e Gravidez, 2025: distinguir as atualizações de protocolo.
  https://www.revportdiabetes.com/wp-content/uploads/2025/11/REC_Consenso-Diabetes-e-Gravidez-Atualizacao-2025_85-129.pdf

- ISSHP 2021, publicada em 2022: PA, confirmação e proteinúria.
  https://isshp.org/wp-content/uploads/2023/09/ISSHP-2021-guidelines.pdf
- DGS, Norma 001/2023, atualizada em 23/03/2026: organização de cuidados.
- As janelas fixas, as quotas, a exclusão FGR × macrossomia e a regra uniforme de redatação são escolhas deste desenho, não recomendações universais.
- INTERGROWTH-21st: padrões de tamanho ao nascer e referência específica para muito pré-termo; selecionar os materiais aplicáveis, sem extrapolar a sua cobertura ou confundir crescimento pós-natal com tamanho ao nascer.
  https://intergrowth21.tghn.org/newborn-size-birth/
  https://intergrowth21.tghn.org/very-preterm-size-birth/
  https://intergrowth21.ndog.ox.ac.uk/
- Villar et al., 2014, padrões internacionais de tamanho ao nascer por idade gestacional e sexo, Lancet 384(9946):857–868.
  https://pubmed.ncbi.nlm.nih.gov/25209487/
- Villar et al., 2016, referências de tamanho ao nascer em muito pré-termo; doi:10.1016/S0140-6736(16)00384-6.
  https://pubmed.ncbi.nlm.nih.gov/26898853/
- ISUOG, 2019, Ultrasound assessment of fetal biometry and growth; fórmulas e calculadoras de biometria identificam diferentes âmbitos de uso.
  https://www.isuog.org/resource/isuog-practice-guidelines-ultrasound-assessment-of-fetal-biometry-and-growth-pdf.html
  https://www.isuog.org/clinical-resources/fetal-biometry.html

Na documentação de geração, identificar as fontes e versões efetivamente implementadas, com equações ou tabelas e unidades. A presença de uma ligação bibliográfica não demonstra que o código implemente a referência. Se o método for aproximação, chamar-lhe aproximação e explicitar o seu âmbito. Não afirmar segurança clínica, validação profissional ou aptidão para publicação apenas

porque estas instruções foram acrescentadas ao prompt.

==========

19. NOTA PARA UTILIZAÇÃO EM MACHINE LEARNING / CLUSTERING

==========

O dataset deve permitir análise de ML e XAI sem leakage estrutural desnecessário.

No relatório metodológico, identificar pares/grupos de variáveis em que uma flag é derivada deterministicamente de uma variável-base, por exemplo:

- gestational_age_at_delivery_weeks -> preterm_birth
- birth_weight_g -> macrosomia
- hemoglobin_* -> anemia_*
- EPDS_score -> EPDS_ge_12
- estimated_fetal_weight_third_trimester_percentile -> fetal_growth_restriction
- BP + proteinúria -> gestational_hypertension / preeclampsia

Não eliminar estas variáveis do dataset, pois fazem parte do schema fechado.

Porém, documentar que em tarefas de clustering ou modelação não supervisionada não é recomendável incluir simultaneamente, sem justificação, a variável-base contínua e a respetiva flag determinística, pois isso pode duplicar artificialmente o peso do mesmo fenómeno clínico.

==========

20. CRITÉRIO FINAL DE ACEITAÇÃO

==========

O resultado solicitado é uma coorte gerada de acordo com este desenho:

- exatamente 5000 trajetórias e 162 variáveis;
- nomes, unidades, categorias e precisões preservados;
- percentil fetal exportado como inteiro de 1 a 99;
- idade ecográfica inteira de 63 a 97 dias neste desenho;
- altura uterina puerperal na convenção e no momento documentados;
- medidas e flags consistentes, incluindo Hb, FGR e dose de ácido fólico;
- EDD ajustada e idade gestacional baseadas na mesma origem temporal;
- eventos e observações temporalmente coerentes, com truncagem pelo parto;
- visit8 entre 28 e 42 dias após o parto, com os campos associados coerentes;
- PA repetida gerada conjuntamente no suporte operacional documentado, sem substituições por pisos/tetos ou eliminação da hipertensão;
- pelo menos 1500 controlos definidos pelas condições-alvo e observações necessárias, sem usar referenciação isolada ou desconhecidos como negativos;
- enriquecimento obtido por trajetórias completas;
- condições patológicas e heterogeneidade preservadas;
- dicionário e assunções suficientes para interpretação posterior.

Para a componente de crescimento e nascimento, entregar a definição da fórmula de peso fetal, da curva de percentis e da referência neonatal efetivamente usadas, com cobertura da idade gestacional e relação entre as unidades. Não usar uma função normal sintética ou uma reta extrapolada como substituto não declarado de uma referência clínica. Indicar a quantização dos percentis e as limitações de observabilidade quando datas ou sexo constam apenas de metadados auxiliares.

Indicar expressamente qualquer variável com definição pendente. A conservação

de second_trimester_biometry como NA quando o significado não é esclarecido é uma entrega parcial nessa variável, não a resolução da lacuna. Não inventar um valor para apresentar as 162 colunas como inteiramente prontas para uso.

Não acrescentar a este pedido uma fase de execução de ferramentas externas, pedidos de ficheiros dessas ferramentas ou declarações de aprovação clínica. O dataset e a sua documentação serão avaliados numa etapa posterior.

==========

FIM DO PROMPT

==========